

고정된 마감 아래의 근거 기반 리뷰

ICML 형식 리뷰를 위한 신뢰성 계약

이해용 한국어 해설본

익명 Track 2 프로젝트

2026 년 7 월 12 일

이 문서는 이해를 돕기 위한 한국어 동반본이다. 공식 제출 형식은 영문 *ICML* 보고서 *technical-report.pdf* 를 기준으로 한다.

요약

시간 제한이 있는 과학 리뷰에서는 근거의 질과 안정적인 일괄 실행이 결합된다. 본 보고서는 논문 신원을 동결하고, 플랫폼 부작용을 하나의 Root 코디네이터로 제한하며, 최대 세 개의 논문별 Review Worker 를 사용하도록 설계한 익명 Track 2 시스템을 제시한다. 각 Worker 는 비공개 claim map, falsification, score anchoring, consistency pass 를 수행한다. 결정론적 검증 후에는 복합 고위험 초안만 선택적으로 제한된 verifier 경로에 들어간다. 명시적 risk sidecar 와 mock verifier 가 이 경로를 로컬에서 실행하고, native 검증은 별도 Root orchestration 으로 유지한다. 10 편 규모의 결정론적 합성 모의실험 세 번에서 30 개 초안 모두 mock verified completion 에 도달했고, 스키마 유효성은 100% 였으며 중복 post 시도와 중복 먹등성 키는 없었다. 장애 실행에서는 malformed output, Worker timeout, claim timeout, post timeout 을 각각 한 번 복구했다. 별도의 두 프로세스 resume 검사는 4 편까지의 원장 prefix 와 완료 산출물을 보존한 뒤 10/10 에 도달했다. 규칙 기반 seeded-fixture 검사는 one-finding baseline 의 F1 0.6667 에 비해 F1 1.0 을 기록했다. 이 결과는 로컬 계약과 복구 로직만 검증하며, LLM 리뷰 품질, 사람 평가와의 일치도, live-platform 처리량을 입증하지 않는다.

1 문제와 계약

Track 2 는 ICML 형식의 리뷰 에이전트와 동결 논문에 대한 구조화 리뷰를 요구한다. live 운영 시간은 25 분이므로 리뷰 품질과 일괄 실행 신뢰성은 서로 연결된다. 잘 작성된 초안도 유실되거나 중복되거나 확인 없이 post 되면 쓸모가 없다. 따라서 이 시스템은 근거 신원, 리뷰 유효성, 부작용 상태를 하나의 end-to-end 계약으로 다룬다.

공식 upstream Skill 은 commit `a9f4f258...153473f` 에 고정되어 있다. Track 2-only 경로에는 새로운 학습, GPU, 실험 서비스, 학습 metric 이 필요하지 않다. 대신 동결된 논문과 근거 hash, 독립적으로 동결된 에이전트 정의, 구조화 결과, 제공 근거가 부족할 때의 명시적 보고가 필요하다. 로컬 wrapper 는 upstream 의 *Contribution* 평가를 보존하면서 행사 필드인 *Significance*, *Originality*, *Comment* 를 유지하며, 서로 다른 필드를 변환하지 않는다.

2 시스템 설계

2.1 플랫폼 부작용의 단일 소유자

Root 코디네이터만 assignment discovery, claim, 원격 status 확인, review post, 공유 원장 갱신을 수행할 수 있다. live 설계는 최대 세 개의 지속형 Review Worker 를 사용한다. 각 Worker 는 한 번에 하나의 동결 논문 manifest 를 받고 구조화된 ReviewDraft 만 반환한다. 이 권한 경계는 Worker 재시도가 중복 플랫폼 동작으로 이어지는 것을 막는다. 합성 모의실험 runtime 은 이 제한된 queue 를 결정론적 로컬 drafting 으로 모델링하며, native-agent 품질 실행이 아니다.




그림 1: 권한은 구조적으로 좁게 제한된다. Worker 는 원격 부작용을 만들거나 공유 상태를 변경할 수 없다.

2.2 동결 입력과 근거 추적

Worker 실행 전에 코디네이터는 논문 식별자, 논문 파일 신원, SHA-256 과 크기, 근거 파일 신원과 hash 및 크기, 집계 input/evidence hash, agent version, canonical task-prompt asset hash, schema hash 를 논문별 manifest 에 기록한다. Native Worker instruction 은 wrapper-package manifest 로 별도 동결하고, 그 manifest hash 는 batch metadata 에 기록한다. 동결 corpus 는 허용 경로를 제공하고, Root 는 active lease 를 manifest 와 분리해 발급한다. 안전하지 않은 논문 식별자는 산출물이나 원장을 쓰기 전에 거부된다. Worker 는 중앙 strength 와 weakness 에 대해 page, section, table, figure 또는 saved-result 위치와 함께 동결 신원 및 Root 가 발급한 lease 신원을 반환해야 한다. 신원 불일치는 실행을 차단하며 targeted repair 경로로 들어갈 수 없다.

2.3 정규 리뷰 구조

초안에는 Summary, Strengths, Weaknesses, Questions, Ethics and Limitations, Evidence Trace, score rationales 가 포함된다. Soundness, Presentation, Contribution, Significance, Originality, Overall Recommendation, Confidence, constructive Comment 는 서로 독립된 값이다. 결정론적 validator 는 필수 필드, 정수 범위, 비어 있지 않은 prose, lease 와 paper identity, evidence location, 금지된 filler text 를 검사한다. 논문당 targeted repair 는 schema 와 calibration 오류를 합쳐 최대한 한번 허용되며 동결 신원을 바꿀 수 없다.

2.4 근거 우선 calibration

JSON 을 출력하기 전에 Worker 는 비공개 claim map 을 만들고, falsification pass 를 수행하며, 각 score 를 독립적으로 anchor 하고, claim, rationale, score, confidence, comment 사이의 consistency 를 검사한다. 결정론적 검증 뒤 Root 는 복합 고위험 subset 만 하나의 read-only verifier 로 보낼 수 있다. 이 경로는 $\min(3, \lceil 0.3N \rceil)$ 편, 논문당 20 초, T+15 이전, validated backlog 가 최대 2 일 때로

제한된다. 일반 초안은 fast path 를 사용한다. 이는 실행 정책 상태 전이를 명시적 risk sidecar 와 결정론적 mock verifier 로 DRY-RUN 에서 실행한다. Native 검증은 별도 Root 소유 Codex 작업이며, 이는 control flow 를 검증할 뿐 unseen paper 의 품질 향상을 입증하지 않는다.

3 실행 방법

운영자는 먼저 staged wrapper manifest 를 검증하고, 두 Skill 과 세 native-agent 정의를 project .codex 에 설치한 뒤 새 Codex session 을 시작한다. 호출 순서는 \$auto-research 에서 Track 2-only frozen-paper 경로를 선택하고, 이어서 \$ralphthon-track2-review-agent 를 실행하는 것이다. Root 는 각 assignment 를 동결하고, 논문별 drafting 을 분배하며, deterministic validation 과 제한된 risk gate 를 실행하고, post 시도 전에 outbox 와 clipboard 산출물을 쓴다.

포함된 run_batch.py 는 manifest 동결용 BUILD 와 mock-only DRY-RUN 을 지원한다. 명시적 --calibration mock 과 sidecar 로 verifier gate 와 repair 를 실행하며, output 생성 전에 LIVE 를 거부한다. 승인된 live 시작 시점에는 Skill 이 최대 45 초의 read-only contract discovery 를 수행한다. Assignment, field, success marker 의미를 검증할 수 없으면 selector-free manual fallback 으로 전환하되 동일한 validation 및 status-first 규칙을 유지한다.

3.1 운영 체크리스트

실제 실행 순서는 다음 네 단계다.

1. python3 scripts/install-track2-codex.py --check-staging 으로 패키지를 확인한 뒤, 같은 명령을 --install 옵션으로 다시 실행하고 새 Codex session 을 연다.
2. \$auto-research 를 호출해 Track 2-only 경로를 선택한다. 이어서 다음 wrapper Skill 을 호출한다.

`$ralphthon-track2-review-agent`

이때 BUILD, DRY-RUN, 또는 승인된 LIVE workflow 중 하나를 명시한다.

3. 로컬 준비에서는 run_batch.py 에 --mode BUILD, --papers CORPUS, --output-dir DIR 을 넘긴다. 복구 리허설에서는 mode 를 DRY-RUN 으로 바꾸고 --workers 3 을 사용한다. 생성된 manifest, ledger, outbox, clipboard, audit 결과를 보존한다.
4. LIVE 에서는 bundled CLI 를 사용하지 않는다. Root 가 제한된 read-only discovery 와 직렬화된 플랫폼 부작용을 담당하고, 관찰된 계약이 불완전하면 MANUAL_PLATFORM.md 로 전환한다. 원격 완료를 확인했거나 unresolved 상태를 명시적으로 기록했을 때만 실행을 종료한다.

4 신뢰성 모델

코디네이터는 기본 high-water mark 가 3 인 제한된 queue, 논문당 하나의 active lease, 원자적 snapshot 교체를 사용하는 append-only ledger, post intent 용 idempotency key 를 사용한다. timeout 된 Worker 는 제한된 retry 정책에 따라 한 번 다시 queue 에 들어갈 수 있고, Root 는 결정론적 lease 를 유지한다. malformed output 은 공유 targeted repair 경로에 들어가기 전에 validator-reject 상태와 검증 오류를 기록한다.

Claim 과 post timeout 은 결과가 모호한 부작용이다. 따라서 코디네이터는 같은 동작을 다시 실행하기 전에 status 를 조회한다. post 시도는 원격 상태가 verified success 또는 안전한 retry 로 해소될 때까지 post_unknown 으로 남는다. 유일한 live 완료 조건은 posted_verified == assigned_count 이다. Mock 완료는 mock 근거로만 보고하며 live-platform 성능으로 제시하지 않는다.

5 평가 프로토콜

평가는 quality 계약과 runtime 계약으로 나뉜다. Quality case 는 candidate generation 전에 issue type 과 evidence location 으로 seeded 된다. 첫 번째 명시적 result sentence 를 선택하는 고정 one-finding rule 이 naive baseline 이다. 결정론적 matching 은 paper ID, finding type, normalized locator 를 사용해 TP, FP, FN 을 계산한다. Finding text 는 audit 을 위해 보존하지만 match 에는 포함되지 않으므로 이 검사는 semantic correctness 를 평가하지 않는다. Acceptance threshold 는 결과 관찰 뒤에 고르는 대신 fixture 와 함께 미리 저장된다.

Runtime 평가는 10 개의 mock assignment 와 세 번의 독립 반복을 사용한다. assigned/verified-complete count, schema validity, duplicate post count, raw event 기반 latency 를 기록한다. 별도 장애 시나리오는 malformed JSON, Worker timeout, claim timeout, post timeout 을 주입하고 원장을 한 번 in-process 로 다시 연다. 각 시나리오는 verified recovery 또는 명시적 unresolved state 를 보여야 하며, 조용한 유실은 통과가 아니다.

6 합성 모의실험 결과

표 1은 결정론적 synthetic fixture 와 mock adapter 만 보고한다. 세 번의 정상 실행에서 30 개 assignment 모두 mock posted_verified 에 도달했고, 30 개 초안 모두 schema 를 통과했으며, duplicate post attempt 와 duplicate idempotency key 는 0 이었다. 별도의 10 편 실행은 malformed JSON output, Worker timeout, claim timeout, post timeout 을 각각 한 번 주입하고 원장을 한 번 in-process 로 다시 열었다. 주입된 조건은 각각 한 번 복구되었고, 10 개 초안 모두 유효하고 mock-verified 상태에 도달했으며 duplicate post attempt 는 0 이었다. 완료 뒤 no-op rerun 에서도 ledger 와 outbox 는 byte-identical 상태를 유지했다.

합성 모의실험 runtime 의 OS-process resume 동작은 별도로 검사했다. 첫 프로세스는 mock-verified 4 편 뒤 exit code 75 로 종료했다. 새 프로세스는 같은 output directory 와 input 을 열고 10/10 mock verification, schema validity 10/10, duplicate post/key 0 으로 exit 0 에 도달했다. 4 편까지의 ledger prefix 와 완료된 manifest/outbox byte 도 보존됐다.

표 1: 결정론적 합성 모의실험 runtime 근거. Production claim 또는 post 는 발생하지 않았다.

실행	검증 완료	Schema	중복
정상 실행 3 회	30/30	30/30	0
장애 주입	10/10	10/10	0
두 프로세스 resume	10/10	10/10	0

사전 동결된 seeded synthetic issue set 에서 deterministic fixture-matching runtime 은 동결된 type/location target 20 개 모두에 finding 을 출력해 TP 20, FP 0, FN 0, F1 1.0 을 기록했다. 고정 one-finding baseline 은 TP 10, FP 0, FN 10, F1 0.6667 이었다. 동결된 rule 에서 두 방법 모두

location accuracy 1.0 이었다. Finding prose 를 채점하지 않으므로 이 결과는 scientific judgment 나 semantic review quality 가 아니라 fixture type/location coverage 를 검사한다.

표 2: Seeded synthetic issue 의 type/location coverage 평가.

시스템	TP	FP	FN	F1
Fixture-matching runtime	20	0	0	1.0000
One-finding rule	10	0	10	0.6667

Runtime 과 quality 값은 다음 동결 기준 파일에서 가져왔다.

evidence/mock-validation-final-20260712T1335KST/aggregate.json

실제 두 프로세스 결과는 다음 파일에서 가져왔다.

evidence/process-restart-proof/aggregate.json

위 값은 저장 값의 직접 집계 또는 소수점 넷째 자리 반올림이다.

Post-build evaluator 는 70 개 regression test 를 모두 통과했고, installed/staged package 의 정확한 일치, 제한된 calibration 경로의 실행, 정상 합성 모의실험의 30/30 유효·duplicate-free 완료를 확인했다. Native Worker instruction surface 는 4,096-byte budget 이내인 2,224 bytes 다. 이는 packaging 과 fast-path 보존을 검증하지만 calibration 의 과학적 효과를 입증하지 않는다.

7 산출물과 감사 인계

통과한 로컬 실행은 하나의 독립적인 evidence directory 를 남긴다. manifests/는 paper, evidence, prompt, schema, agent 신원을 묶고, outbox/와 clipboard/는 post 시도 전에 검증된 review payload 를 보존한다. ledger.jsonl, 원자적 state snapshot, summary.json 은 상태 전이와 완료 수를 기록한다. 이 파일은 복구 입력이며 원격 제출 성공의 증거가 아니다.

재시작은 동일한 output directory 와 동결 입력을 다시 사용한다. 이미 검증된 논문은 건너뛰지만, manifest 신원이 달라지면 덮어쓰지 않고 hard failure 로 종료한다. Receipt audit 은 assigned paper ID 와 ledger 의 posted_verified 상태를 대조한다. Live manual lane 에서 Root 는 실제 플랫폼 success marker 를 관찰한 뒤에만 이 상태를 기록한다. outbox 파일이나 로컬 mock 상태를 live receipt 로 승격하지 않는다.

최종 live audit 은 T+23:30 에 시작하고 T+24:30 에는 새로운 플랫폼 부작용을 중단한다. 인계 시 assigned, drafted, schema-valid, post_unknown, posted_verified, unresolved 수와 함께 mock 또는 live label 을 명시한다. 따라서 부분 완료 batch 도 성공으로 숨기지 않고 감사 가능한 unresolved 결과로 남는다.

8 한계

Mock run 통과만으로 live-platform throughput, submission success, unseen research 에서의 review correctness, human judgment 와의 agreement 를 입증할 수 없다. Runtime elapsed time 은 in-process synthetic fixture 를 반영하므로 live speed claim 에 사용하지 않는다. Worker-timeout 근

거는 mock adapter `TimeoutError` 와 제한된 recovery 를 사용하며, 실행 중 thread 가 강제로 종료됐음을 입증하지 않는다.

구조적 한계도 있다. Evidence location 은 claim 이 도출된 위치를 보여줄 수 있지만 claim 의 정확성을 보장하지 않는다. Originality 평가는 제출 논문과 제공 reference 로 제한된다. 결정론적 schema validator 는 malformed review 를 거부할 수 있지만 scientific quality 를 인증할 수 없다. Live adapter 는 read-only discovery 로 실제 platform contract 를 확인하기 전까지 정의되지 않으며, 본 보고서는 endpoint 나 selector 를 가정하지 않는다. Mock verifier 는 risk, gate, PASS/REPAIR, 공유 repair, 재검증, 감사 상태 전이를 실행하지만 독립적인 과학 판정자는 아니다. Native 검증은 Root 가 별도로 orchestration 하며 unseen-paper 품질과 inter-reviewer agreement 에 미치는 효과는 측정하지 않았다.

9 결론

이 설계는 동결 근거 신원, 좁은 부작용 소유자, 제한된 논문별 Worker, 비공개 evidence-first calibration, 결정론적 validation, compound risk gate, status-first reconciliation 을 결합한다. 평가 계약은 fixture coverage 를 semantic review quality 와 구분하고, mock evidence 를 live outcome 과 분리한다. 결정론적 mock run 은 동결 runtime, type/location coverage, 두 프로세스 resume 검사를 충족했지만 live-platform 동작과 unseen-paper review quality 는 측정하지 않았다.

참고문헌

- [1] Ralphthon ICML organizers. Auto Research Skill, Track 2-only frozen-paper path. Repository commit `a9f4f2583648ef4ca54f980f951ae393d153473f`, 2026.
- [2] Ralphthon ICML organizers. Track 2 rules, 2026.